

Αναγνώριση Προτύπων - 1<sup>η</sup> Σειρά Ασκήσεων

Ακοδ. Έτος 2021-2022

Όνοματεπώνυμο: Χρήστος Δημόπουλος

Αρ. Μητρώου: 031 17 037

e-mail address: chrisdim1999@gmail.com

Άσκηση 1.1: (Maximum Likelihood estimation)

Έστω ότι η μεταβλητή  $x$  ακολουθεί μια κατανομή τύπου Erlang:

$$p(x|\theta) = \theta^2 x e^{-(\theta x)} u(x)$$

όπου  $u(x)$  η βηματική συνάρτηση:  $u(x) = \begin{cases} 1, & \text{if } x > 0 \\ 0, & \text{if } x < 0 \end{cases}$

Υποθέτουμε ότι τα δείγματα  $\mathcal{D} = \{x_1, x_2, \dots, x_n\}$  επιλέγονται ανεξάρτητα μεταξύ τους σύμφωνα με την κατανομή  $p(x|\theta)$  (independent & identically distributed).

Maximum Likelihood Estimation for parameter  $\theta$ :

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} P(\mathcal{D}|\theta) \xrightarrow[\text{αύξουσα}]{\text{συνέχεια}} \hat{\theta} = \underset{\theta}{\operatorname{argmax}} \ln P(\mathcal{D}|\theta)$$

$$x_i \text{ i.i.d.} \Rightarrow \hat{\theta} = \underset{\theta}{\operatorname{argmax}} \ln \prod_{i=1}^n p(x_i|\theta) = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \ln p(x_i|\theta)$$

$$\begin{aligned} \text{όπου: } \ln p(x_i|\theta) &= \ln \left( \theta^2 x_i e^{-(\theta x_i)} u(x_i) \right) = 2 \ln \theta + \ln x_i - \theta x_i + \ln u(x_i) \\ &= 2 \ln \theta - \theta x_i + \ln(x_i \cdot u(x_i)) \end{aligned}$$

$$\text{Άρα: } \ln P(\mathcal{D}|\theta) = \sum_{i=1}^n \ln p(x_i|\theta) = 2n \ln \theta - \theta \sum_{i=1}^n x_i + \sum_{i=1}^n \ln(x_i \cdot u(x_i))$$

Προκειμένου να βρω το μέγιστο της ανωτέρω συνάρτησης, βρίσκω το σημείο μηδενισμού της παραγώγου της ως προς την παράμετρο  $\theta$ :

$$\frac{\partial \ln p(D|\theta)}{\partial \theta} = 0 \Rightarrow \frac{2n}{\theta} - \sum_{i=1}^n x_i = 0, \theta \neq 0$$

$$\Rightarrow \hat{\theta} = \frac{2n}{\sum_{i=1}^n x_i} = \frac{2}{\bar{x}}, \text{ όπου } \bar{x} = \frac{\sum_{i=1}^n x_i}{n} \text{ ο αριθμητικός μέσος όρος των } n \text{ δειγμάτων.}$$

### Άσκηση 1.2: (Minimax Criterion)

Έστω το minimax κριτήριο για τη zero-one συνάρτηση κόστους, δηλαδή  $\lambda_{11} = \lambda_{22} = 0$  και  $\lambda_{12} = \lambda_{21} = 1$ .

$$R(P(w_1)) = \lambda_{22} + (\lambda_{12} - \lambda_{22}) \int_{R_1} P(x|w_2) dx + P(w_1) \left[ (\lambda_{11} - \lambda_{22}) + (\lambda_{21} - \lambda_{11}) \int_{R_2} P(x|w_1) dx - (\lambda_{12} - \lambda_{22}) \int_{R_1} P(x|w_2) dx \right] \quad [1]$$

$$\stackrel{\text{zero-one}}{\Rightarrow} R(P(w_1)) = \int_{R_1} P(x|w_2) dx + P(w_1) \cdot \left[ + \int_{R_2} P(x|w_1) dx - \int_{R_1} P(x|w_2) dx \right]$$

1.) Η minimax λύση δίνεται θέτοντας την παράγωγο του ανωτέρω κριτηρίου ως προς την a-priori  $P(w_1)$  ίση με μηδέν:

$$\frac{\partial R(P(w_1))}{\partial P(w_1)} = 0 \Rightarrow \int_{R_2} P(x|w_1) dx - \int_{R_1} P(x|w_2) dx = 0$$


$$\Rightarrow \int_{R_2} P(x|w_1) dx = \int_{R_1} P(x|w_2) dx$$

2) Η παραπάνω λύση δεν είναι απαραίτητα μοναδική. Δίνεται το εξής αντίπαλο-  
 δείγμα:

Έστω ίσες α-priori  $P(w_1) = P(w_2) = 1/2$  και επίσης:

$$P(x|w_1) = \begin{cases} 1, & -1 \leq x \leq 1 \\ 0, & \text{otherwise} \end{cases} \quad P(x|w_2) = \begin{cases} 1, & 0 \leq x \leq 2 \\ 0, & \text{otherwise} \end{cases}$$

1<sup>st</sup> Case:  $R_1 = [0, 1]$  και  $R_2 = (-\infty, 0) \cup (1, +\infty)$




Τότε:

$$\int_{R_1} P(x|w_2) dx = \int_0^1 P(x|w_2) dx = \int_0^1 1 dx = 1$$

$$\int_{R_2} P(x|w_1) dx = \int_{-1}^0 1 dx + \int_1^{\infty} 0 dx = 1$$

Ανταδιν  $\int_{R_2} P(x|w_1) dx = \int_{R_1} P(x|w_2) dx$

2<sup>nd</sup> Case:  $R_1 = [-0.5, 0.5]$  και  $R_2 = (-\infty, -0.5) \cup (0.5, +\infty)$



Τότε:

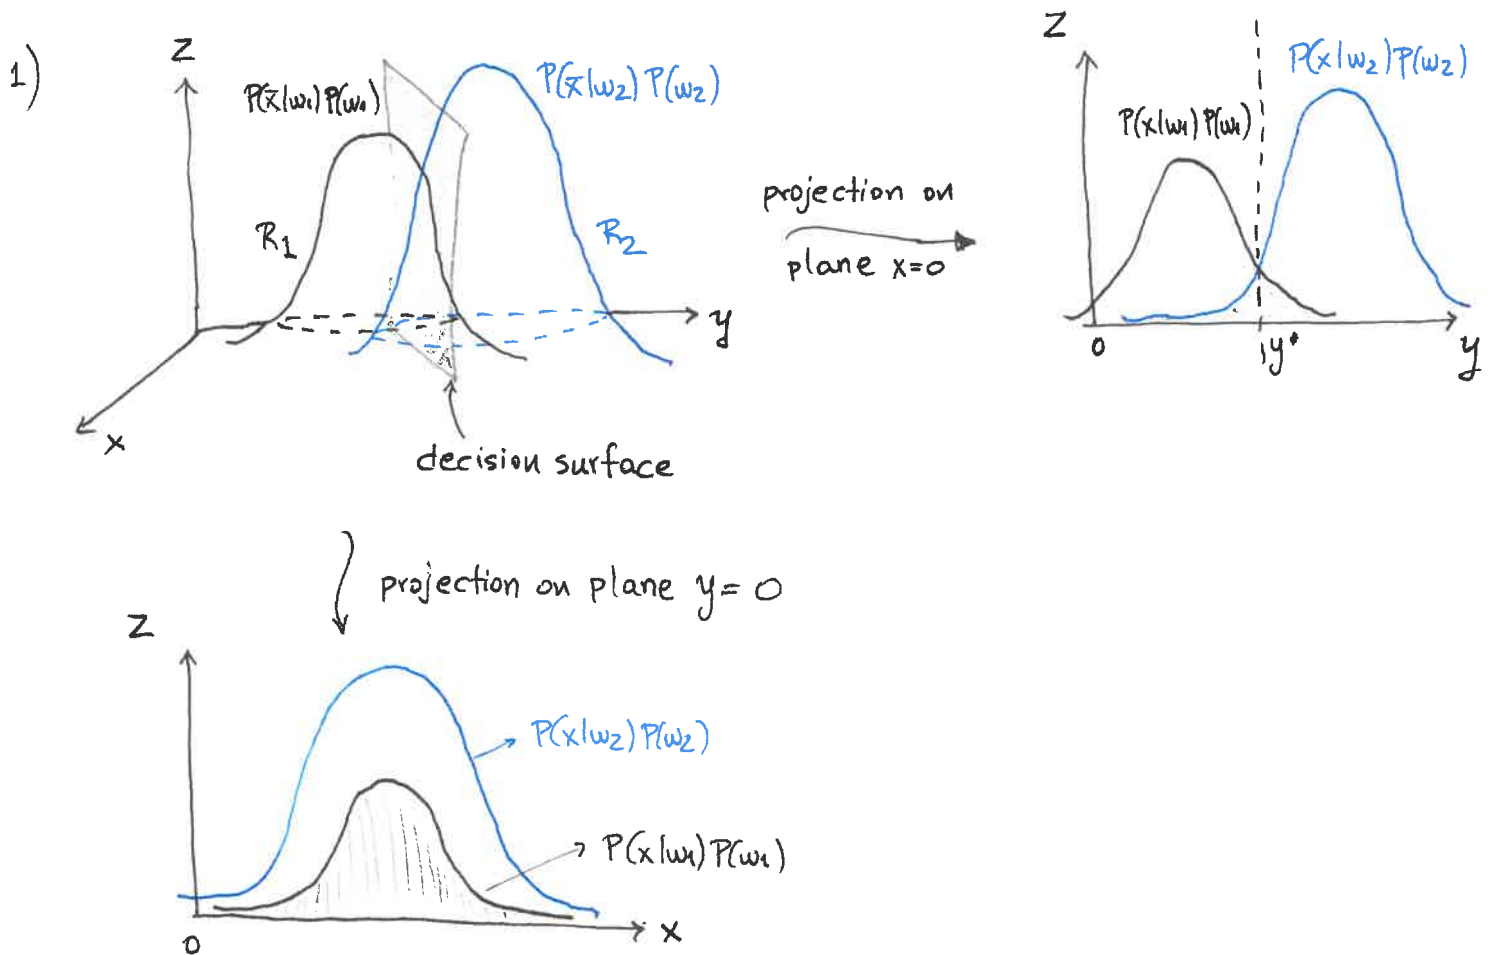
$$\int_{R_1} P(x|w_2) dx = \int_{-0.5}^{0.5} P(x|w_2) dx = \int_{-0.5}^{0.5} 1 dx = 0.5$$

$$\int_{R_2} P(x|w_1) dx = \int_{-1}^{-0.5} 1 dx + \int_{0.5}^1 1 dx + \int_{1}^{\infty} 0 dx = 0.5$$

Ανταδιν  $\int_{R_2} P(x|w_1) dx = \int_{R_1} P(x|w_2) dx$

### Άσκηση 1.3 : (Bayes Error)

Έστω δύο ανεξάρτητες κατανομές  $p(x|w_i)$  με priors  $p(w_i)$ ,  $i=1,2$ . Υποθέτουμε ότι οι κατανομές αυτές ορίζονται για ένα χώρο διαστάσεων  $d=2$ .



Έστω ότι οι κατανομές μας είναι κανονικές (normal distributions). Χωρίς βλάβη της γενικότητας, προβάλλουμε τις κατανομές στο επίπεδο  $y=0$ , δηλαδή μειώνουμε τη διαστατικότητα του προβλήματος σε  $d'=d-1=1$ , και υποθέτουμε ότι ισχύει  $P(x|w_1)P(w_1) < P(x|w_2)P(w_2)$ ,  $\forall x \in \mathbb{R}$ . Τότε, αν ονομάσουμε  $R_2$  την περιοχή στην οποία  $P(x|w_2)P(w_2) > P(x|w_1)P(w_1)$ , θα ισχύει:

$$P(\text{error} | 1D) = \int_{R_2} P(x|w_1) P(w_1) dx = \int_{-\infty}^{+\infty} P(x|w_1) P(w_1) dx = P(w_1) \cdot \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{(x-\mu_1)^2}{2\sigma^2}} dx$$

$$= P(w_1). \quad (1)$$

Για τον χώρο διαστάσεων  $d=2$ , ορίζουμε τις περιοχές:

•  $R_1$ : όπου  $P(\bar{x}|w_1)P(w_1) > P(\bar{x}|w_2)P(w_2)$

•  $R_2$ : όπου  $P(\bar{x}|w_2)P(w_2) > P(\bar{x}|w_1)P(w_1)$

Τότε:  $P(\text{error} | 2D) = \iint_{R_1} P(\bar{x}|w_2)P(w_2) d\bar{x} + \iint_{R_2} P(\bar{x}|w_1)P(w_1) d\bar{x} \quad (2)$

Θα κινηθούμε με αναγωγή εις άτονον. Έστω ότι ισχύει:

$$P(\text{error} | 2D) > P(\text{error} | 1D)$$

(1), (2)  
 $\Rightarrow \iint_{R_1} P(\bar{x}|w_2)P(w_2) d\bar{x} + \iint_{R_2} P(\bar{x}|w_1)P(w_1) d\bar{x} > P(w_1)$

$$\Rightarrow \iint_{R_1} P(\bar{x}|w_2)P(w_2) d\bar{x} > P(w_1) \cdot \left[ 1 - \iint_{R_2} P(\bar{x}|w_1)P(w_1) d\bar{x} \right]$$

$$\Rightarrow \iint_{R_1} P(\bar{x}|w_2)P(w_2) d\bar{x} > P(w_1) \iint_{R_1} P(\bar{x}|w_1) d\bar{x} \quad , \text{δίου } R_1 \cup R_2 = \mathbb{R}^2$$

$$\Rightarrow \iint_{R_1} P(\bar{x}|w_2)P(w_2) d\bar{x} > \iint_{R_1} P(\bar{x}|w_1)P(w_1) d\bar{x}$$

Άτοπο, αφού εξ ορισμού στην περιοχή  $R_1$  υποθέσαμε ότι ισχύει:

$$P(\bar{x}|w_1)P(w_1) > P(\bar{x}|w_2)P(w_2) \geq 0$$

Συνεπώς, θα ισχύει

$$P(\text{error} | 2D) \leq P(\text{error} | 1D)$$

2) Έστω ότι οι κατανομές πλέον είναι οποιαδήποτε μορφής. Θεωρούμε μια γραμμή  $\ell$  στον χώρο διάστασης  $d=2$  και την προβολή της στον χώρο διάστασης  $d'=1$ .

Τότε:

$$\begin{aligned} P(\text{error} | 2D) &= \int_{\ell} \min \{ P(\bar{x} | w_1) P(w_1), P(\bar{x} | w_2) P(w_2) \} dx \\ &= \int_{\Gamma_2} P(\bar{x} | w_1) P(w_1) dx + \int_{\Gamma_1} P(\bar{x} | w_2) P(w_2) dx \end{aligned}$$

όπου  $\Gamma_1$ : το τμήμα της γραμμής  $\ell$  για το οποίο  $P(\bar{x} | w_1) P(w_1) > P(\bar{x} | w_2) P(w_2)$

$\Gamma_2$ : το τμήμα της γραμμής  $\ell$  για το οποίο  $P(\bar{x} | w_2) P(w_2) > P(\bar{x} | w_1) P(w_1)$ .

Προβάλλοντας στον χώρο  $d=1$ , υποθέτουμε χωρίς βλάβη της γενικότητας ότι

ισχύει:

$$\int_{\ell} P(x | w_1) P(w_1) dx < \int_{\ell} P(x | w_2) P(w_2) dx$$

Τότε:

$$\begin{aligned} P(\text{error} | 1D) &= \int_{\ell} P(x | w_1) P(w_1) dx = \int_{\Gamma_1 \cup \Gamma_2} P(x | w_1) P(w_1) dx = \\ &= \int_{\Gamma_1} P(x | w_1) P(w_1) dx + \int_{\Gamma_2} P(x | w_1) P(w_1) dx \end{aligned}$$

Όμως στο τμήμα  $\Gamma_1$  υποθέσαμε ότι  $P(x | w_1) P(w_1) > P(x | w_2) P(w_2)$

$$\Rightarrow P(x | w_1) P(w_1) = P(x | w_2) P(w_2) + |f(x)|, \text{ για κάποιο } |f(x)| \geq 0.$$

$$\text{Άρα: } P(\text{error} | 1D) = \underbrace{\int_{\Gamma_1} P(x | w_2) P(w_2) dx + \int_{\Gamma_2} P(x | w_1) P(w_1) dx}_{P(\text{error} | 2D)} + \int_{\Gamma_1} |f(x)| dx$$

$$\Rightarrow P(\text{error} | 1D) = P(\text{error} | 2D) + \int_{\Gamma_1} |f(x)| dx \Rightarrow \boxed{P(\text{error} | 1D) \geq P(\text{error} | 2D)}$$


## Άσκηση 1.4: (Perceptrons)

Μας δίνονται 10 διανύσματα χαρακτηριστικών που προέρχονται από δύο κλάσεις  $w_1$  και  $w_2$ :

$$w_1: [2, 1.5]^T, [4, 1]^T, [-3, 3]^T, [-2, 2]^T, [0, 3]^T$$

$$w_2: [-1, 0]^T, [0, 0]^T, [2, -0.5]^T, [1, -1]^T, [-2, 1]^T$$

Σε πρώτο στάδιο, σχεδιάζουμε τα παραπάνω δείγματα στο επίπεδο:



Όπως φαίνεται, τα δείγματα είναι linearly separable. Στη συνέχεια, κάνουμε χρήση του δοθέντος αλγορίθμου perceptron με  $\rho=1$  και  $w(0) = [0, 0]^T$ . Ωστόσο, παρατηρούμε ότι η διάσταση του συγκεκριμένου διανύσματος βαρών δεν επαρκεί για τον γραμμικό διαχωρισμό των δειγμάτων, καθώς δεν υπάρχει ευθεία που να διέρχεται από την αρχή των αξόνων  $(0,0)$  και να χωρίζει τέλεια τα δείγματα στις δύο κλάσεις  $\Rightarrow$  πρέπει να προστεθεί κάποιο bias  $w_0$ .

Για τον λόγο αυτό, ως αρχικό διάνυσμα βαρών έχουμε το  $w(0) = [0, 0, 0]^T$  και επαυξάνουμε τη διάσταση των δειγμάτων, προσθέτοντας έναν επιπλέον άξονα.

$$\cdot x_{11} = [1, 2, 1.5]^T \in W_1 \quad \text{και} \quad w(0)^T x_{11} = 0 \leq 0$$

$$\text{αρα} \quad w(1) = w(0) + \rho x_{11} \Rightarrow \underline{w(1) = [1, 2, 1.5]^T}$$

$$\cdot x_{12} = [1, 4, 1]^T \in W_1 \quad \text{και} \quad w(1)^T x_{12} = 1 + 8 + 1.5 = 10.5 > 0$$

$$\text{αρα} \quad w(2) = w(1)$$

$$\cdot x_{13} = [1, -3, 3]^T \in W_1 \quad \text{και} \quad w(2)^T x_{13} = 1 - 6 + 4.5 \leq 0$$

$$\text{αρα} \quad w(3) = w(2) + \rho x_{13} \Rightarrow \underline{w(3) = [2, -1, 4.5]^T}$$

$$\cdot x_{14} = [1, -2, 2]^T \in W_1 \quad \text{και} \quad w(3)^T x_{14} = 2 + 2 + 9 > 0$$

$$\text{αρα} \quad w(4) = w(3)$$

$$\cdot x_{15} = [1, 0, 3]^T \in W_1 \quad \text{και} \quad w(4)^T x_{15} = 2 + 3 \times 4.5 > 0$$

$$\text{αρα} \quad w(5) = w(4)$$

$$\cdot x_{21} = [1, -1, 0]^T \in W_2 \quad \text{και} \quad w(5)^T x_{21} = 2 + 2 = 4 \geq 0$$

$$\text{αρα} \quad w(6) = w(5) - \rho x_{21} \Rightarrow \underline{w(6) = [1, 0, 4.5]^T}$$

$$\cdot x_{22} = [1, 0, 0]^T \in W_2 \quad \text{και} \quad w(6)^T x_{22} = 1 \geq 0$$

$$\text{αρα} \quad w(7) = w(6) - \rho x_{22} \Rightarrow \underline{w(7) = [0, 0, 4.5]^T}$$

$$\cdot x_{23} = [1, 2, -0.5]^T \in W_2 \quad \text{και} \quad w(7)^T x_{23} = -0.5 \times 4.5 < 0$$

$$\text{αρα} \quad w(8) = w(7)$$

$$\cdot x_{24} = [1, 1, -1]^T \in W_2 \quad \text{και} \quad w(8)^T x_{24} = -4.5 < 0$$

$$\text{αρα} \quad w(9) = w(8)$$

$$\cdot x_{25} = [1, -2, 1]^T \in W_2 \quad \text{και} \quad w(9)^T x_{25} = 4.5 \geq 0$$

$$\text{αρα} \quad w(10) = w(9) - \rho x_{25} \Rightarrow \underline{w(10) = [-1, 2, 3.5]^T}$$

---


$$\cdot x_{11} = [1, 2, 1.5]^T \in W_1 \quad \text{και} \quad w(10)^T x_{11} = -1 + 4 + 3.5 \times 1.5 > 0$$

$$\text{αρα} \quad w(11) = w(10)$$



$$\cdot x_{12} = [1, 4, 1]^T \in w_1 \quad \text{και} \quad w(11)^T x_{12} = -1 + 8 + 3.5 > 0$$

$$\text{αρα} \quad w(12) = w(11)$$

$$\cdot x_{13} = [1, -3, 3]^T \in w_1 \quad \text{και} \quad w(12)^T x_{13} = -1 - 6 + 10.5 = 3.5 > 0$$

$$\text{αρα} \quad w(13) = w(12)$$

$$\cdot x_{14} = [1, -2, 2]^T \in w_1 \quad \text{και} \quad w(13)^T x_{14} = -1 - 4 + 7 = +2 > 0$$

$$\text{αρα} \quad w(14) = w(13)$$

$$\cdot x_{15} = [1, 0, 3]^T \in w_1 \quad \text{και} \quad w(14)^T x_{15} = -1 + 3 \times 3.5 > 0$$

$$\text{αρα} \quad w(15) = w(14)$$

$$\cdot x_{21} = [1, -1, 0]^T \in w_2 \quad \text{και} \quad w(15)^T x_{21} = -1 - 2 = -3 < 0$$

$$\text{αρα} \quad w(16) = w(15)$$

$$\cdot x_{22} = [1, 0, 0]^T \in w_2 \quad \text{και} \quad w(16)^T x_{22} = -1 < 0$$

$$\text{αρα} \quad w(17) = w(16)$$

$$\cdot x_{23} = [1, 2, -0.5]^T \in w_2 \quad \text{και} \quad w(17)^T x_{23} = -1 + 4 - \frac{3.5}{2} = 1.25 \geq 0$$

$$\text{αρα} \quad w(18) = w(17) - \rho x_{23} \Rightarrow \underline{w(18) = [-2, 0, 4]^T}$$

$$\cdot x_{24} = [1, 1, -1]^T \in w_2 \quad \text{και} \quad w(18)^T x_{24} = -2 - 4 = -6 < 0$$

$$\text{αρα} \quad w(19) = w(18)$$

$$\cdot x_{25} = [1, -2, 1]^T \in w_2 \quad \text{και} \quad w(19)^T x_{25} = -2 + 4 = 2 \geq 0$$

$$\text{αρα} \quad w(20) = w(19) - \rho x_{25} \Rightarrow \underline{w(20) = [-3, 2, 3]^T}$$

$$\cdot x_{11} = [1, 2, 1.5]^T \in w_1 \quad \text{και} \quad w(20)^T x_{11} = -3 + 4 + 3 \times 1.5 > 0$$

$$\text{αρα} \quad w(21) = w(20)$$

$$\cdot x_{12} = [1, 4, 1]^T \in w_1 \quad \text{και} \quad w(21)^T x_{12} = -3 + 8 + 3 = 8 > 0$$

$$\text{αρα} \quad w(22) = w(21)$$

$$x_{13} = [1, -3, 3]^T \in W_1 \text{ και } w(22)^T x_{13} = -3 - 6 + 9 = 0 \leq 0$$

$$\text{άρα } w(23) = w(22) + \rho x_{13} \Rightarrow \underline{w(23) = [-2, -1, 6]^T}$$

$$x_{14} = [1, -2, 2]^T \in W_1 \text{ και } w(23)^T x_{14} = -2 + 2 + 12 = 12 > 0$$

$$\text{άρα } w(24) = w(23)$$

$$x_{15} = [1, 0, 3]^T \in W_1 \text{ και } w(24)^T x_{15} = -2 + 18 = 16 > 0$$

$$\text{άρα } w(25) = w(24)$$

$$x_{21} = [1, -1, 0]^T \in W_2 \text{ και } w(25)^T x_{21} = -2 + 1 = -1 < 0$$

$$\text{άρα } w(26) = w(25)$$

$$x_{22} = [1, 0, 0]^T \in W_2 \text{ και } w(26)^T x_{22} = -2 < 0, \text{ άρα } w(27) = w(26)$$

$$x_{23} = [1, 2, -0.5]^T \in W_2 \text{ και } w(27)^T x_{23} = -2 - 2 - 3 = -7 < 0, \text{ άρα } w(28) = w(27)$$

$$x_{24} = [1, 1, -1]^T \in W_2 \text{ και } w(28)^T x_{24} = -2 - 1 - 6 = -9 < 0, \text{ άρα } w(29) = w(28)$$

$$x_{25} = [1, -2, 1]^T \in W_2 \text{ και } w(29)^T x_{25} = -2 + 2 + 6 = 6 \geq 0$$

$$\text{άρα } w(30) = w(29) - \rho x_{25} \Rightarrow \underline{w(30) = [-3, 1, 5]^T}$$

$$x_{11} = [1, 2, 1.5]^T \in W_1 \text{ και } w(30)^T x_{11} = -3 + 2 + 5 \times 1.5 > 0, \text{ άρα } w(31) = w(30)$$

$$x_{12} = [1, 4, 1]^T \in W_1 \text{ και } w(31)^T x_{12} = -3 + 4 + 5 = 6 > 0, \text{ άρα } w(32) = w(31)$$

$$x_{13} = [1, -3, 3]^T \in W_1 \text{ και } w(32)^T x_{13} = -3 - 3 + 15 > 0, \text{ άρα } w(33) = w(32)$$

$$x_{14} = [1, -2, 2]^T \in W_1 \text{ και } w(33)^T x_{14} = -3 - 2 + 10 > 0, \text{ άρα } w(34) = w(33)$$

$$x_{15} = [1, 0, 3]^T \in W_1 \text{ και } w(34)^T x_{15} = -3 + 15 > 0, \text{ άρα } w(35) = w(34)$$

$$x_{21} = [1, -1, 0]^T \in W_2 \text{ και } w(35)^T x_{21} = -3 - 3 = -6 < 0, \text{ άρα } w(36) = w(35)$$

$$x_{22} = [1, 0, 0]^T \in W_2 \text{ και } w(36)^T x_{22} = -3 < 0, \text{ άρα } w(37) = w(36)$$

$$x_{23} = [1, 2, -0.5]^T \in W_2 \text{ και } w(37)^T x_{23} = -3 + 2 - 2.5 < 0, \text{ άρα } w(38) = w(37)$$

$$x_{24} = [1, 1, -1]^T \in W_2 \text{ και } w(38)^T x_{24} = -3 + 1 - 5 < 0, \text{ άρα } w(39) = w(38)$$

$$x_{25} = [1, -2, 1]^T \in W_2 \text{ και } w(39)^T x_{25} = -3 - 2 + 5 = 0 \geq 0$$

$$\text{άρα } w(40) = w(39) - \rho x_{25} \Rightarrow \underline{w(40) = [-4, 3, 4]^T}$$

$$x_{11} = [1, 2, 1.5]^T \in w_1 \text{ και } w(40)^T x_{11} = -4 + 6 + 4 \times 1.5 > 0, w(41) = w(40)$$

$$x_{12} = [1, 4, 1]^T \in w_1 \text{ και } w(41)^T x_{12} = -4 + 12 + 4 > 0, w(42) = w(41)$$

$$x_{13} = [1, -3, 3]^T \in w_1 \text{ και } w(42)^T x_{13} = -4 - 9 + 12 = -1 \leq 0$$

$$\text{άρα } w(43) = w(42) + \rho x_{13} \Rightarrow \underline{w(43) = [-3, 0, 7]^T}$$

$$x_{14} = [1, -2, 2]^T \in w_1 \text{ και } w(43)^T x_{14} = -3 + 14 > 0 \text{ άρα } w(44) = w(43)$$

$$x_{15} = [1, 0, 3]^T \in w_1 \text{ και } w(44)^T x_{15} = -3 + 21 > 0, \text{ άρα } w(45) = w(44)$$

$$x_{21} = [1, -1, 0]^T \in w_2 \text{ και } w(45)^T x_{21} = -3 < 0, w(46) = w(45)$$

$$x_{22} = [1, 0, 0]^T \in w_2 \text{ και } w(46)^T x_{22} = -3 < 0, w(47) = w(46)$$

$$x_{23} = [1, 2, -0.5]^T \in w_2 \text{ και } w(47)^T x_{23} = -3 - 7 \cdot 0.5 < 0, w(48) = w(47)$$

$$x_{24} = [1, 1, -1]^T \in w_2 \text{ και } w(48)^T x_{24} = -3 - 7 = -10 < 0, w(49) = w(48)$$

$$x_{25} = [1, -2, 1]^T \in w_2 \text{ και } w(49)^T x_{25} = -3 + 7 = 4 \geq 0$$

$$\text{άρα } w(50) = w(49) - \rho x_{25} \Rightarrow \boxed{w(50) = [-4, 2, 6]^T}$$

$$x_{11} = [1, 2, 1.5]^T \in w_1 \text{ και } w(50)^T x_{11} = -4 + 4 + 6 \times 1.5 > 0, w(51) = w(50)$$

$$x_{12} = [1, 4, 1]^T \in w_1 \text{ και } w(51)^T x_{12} = -4 + 8 + 6 > 0, w(52) = w(51)$$

$$x_{13} = [1, -3, 3]^T \in w_1 \text{ και } w(52)^T x_{13} = -4 - 6 + 3 \times 6 = 8 > 0, w(53) = w(52)$$

$$x_{14} = [1, -2, 2]^T \in w_1 \text{ και } w(53)^T x_{14} = -4 - 4 + 12 = 8 > 0, w(54) = w(53)$$

$$x_{15} = [1, 0, 3]^T \in w_1 \text{ και } w(54)^T x_{15} = -4 + 3 \times 6 = 14 > 0, w(55) = w(54)$$

$$x_{21} = [1, -1, 0]^T \in w_2 \text{ και } w(55)^T x_{21} = -4 - 2 = -6 < 0, w(56) = w(55)$$

$$x_{22} = [1, 0, 0]^T \in w_2 \text{ και } w(56)^T x_{22} = -4 < 0, w(57) = w(56)$$

$$x_{23} = [1, 2, -0.5]^T \in w_2 \text{ και } w(57)^T x_{23} = -4 + 4 - 3 < 0, w(58) = w(57)$$

$$x_{24} = [1, 1, -1]^T \in w_2 \text{ και } w(58)^T x_{24} = -4 + 2 - 6 < 0, w(59) = w(58)$$

$$x_{25} = [1, -2, 1]^T \in w_2 \text{ και } w(59)^T x_{25} = -4 - 4 + 6 = -2 < 0, w(60) = w(59)$$

Τελικώς, τα δείγματα ξεχωρίζονται πλήρως για διάνυσμα Βαρών

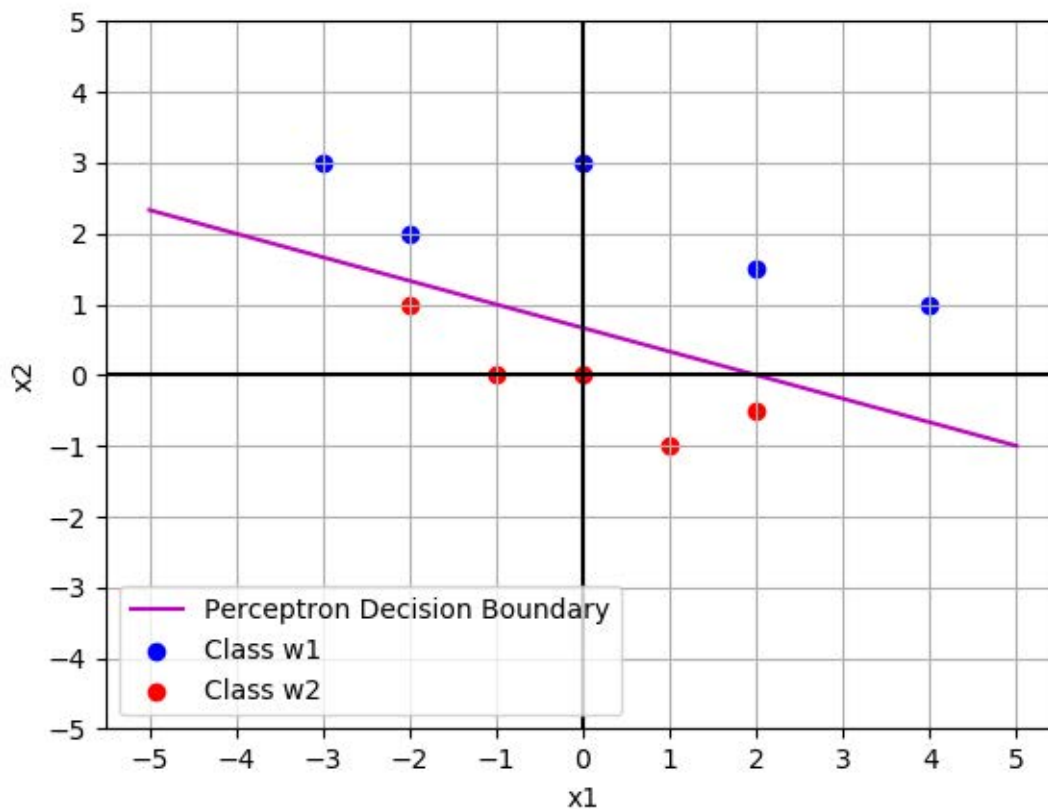
$$\boxed{W = [-4, 2, 6]^T}, \text{ μετά από 60 επαναλήψεις!}$$

Τέλος, η διαχωριστική καμπύλη που αντιστοιχεί στο υπολογισθέν διάνυσμα βαρών είναι:

$$g(\bar{x}) = w_0 + w_1 x_1 + w_2 x_2 = 0 \Rightarrow -4 + 2x_1 + 6x_2 = 0$$

$$\Rightarrow x_2 = -\frac{1}{3}x_1 + \frac{2}{3}$$

Παρακάτω φαίνεται ο διαχωρισμός των δειγμάτων στις δύο κλάσεις μέσω της εν λόγω ευθείας διαχωρισμού:



## Άσκηση 1.5: Kullback-Leibler Divergence

Η μετρική Kullback-Leibler ορίζεται ως εξής:

$$D_{KL}(P_1(x), P_2(x)) = \int P_1(x) \ln \frac{P_1(x)}{P_2(x)} dx \quad (I)$$

και εκφράζει την ποσότητα της πληροφορίας που χάνεται, όταν χρησιμοποιούμε την κατανομή  $P_2(x)$  ως προσέγγιση της κατανομής  $P_1(x)$ .

Έστω ότι η  $P_2(x)$  είναι κανονική κατανομή  $\mathcal{N}(\mu, \Sigma)$  (multidimensional) και χρησιμοποιείται για να προσεγγίσει μια οποιοδήποτε κατανομή  $P_1(x)$ .

Αντικαθιστώντας:

$$P_2(x) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \cdot \exp \left\{ -\frac{(x-\mu)^T \Sigma^{-1} (x-\mu)}{2} \right\}$$

στην (I), έχουμε:

$$\begin{aligned} D_{KL}(P_1, P_2) &= \int P_1(x) \ln P_1(x) dx + \int P_1 \cdot \left[ -\frac{d}{2} \cdot \ln(2\pi) - \frac{1}{2} \ln |\Sigma| - \frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu) \right] dx \\ &= \int P_1(x) \ln P_1(x) dx + \int \frac{1}{2} P_1 \left[ -d \ln(2\pi) - \ln |\Sigma| - (x-\mu)^T \Sigma^{-1} (x-\mu) \right] dx \end{aligned}$$

Αναζητάμε τις παραμέτρους  $\mu, \Sigma$  που ελαχιστοποιούν την "απόσταση" των δύο κατανομών, όπως αυτή εκφράζεται μέσω της KL Divergence. Παραγωγίζουμε ως προς τις παραμέτρους και θέτουμε με μηδέν:

$$\frac{\partial D_{KL}(P_1(x), P_2(x))}{\partial \mu} = - \int \Sigma^{-1} (x-\mu) \cdot P_1(x) dx = 0 \quad \left( \begin{array}{l} \text{δίου } (\Sigma^{-1})^T = (\Sigma^T)^{-1} \\ \text{και } \Sigma = \Sigma^T \\ \text{λόγω συμμετρίας} \end{array} \right)$$

$$\Rightarrow \Sigma^{-1} \int (x-\mu) P_1(x) dx = 0$$

Υποθέτουμε ότι το μητρώο  $\Sigma$  είναι non-singular ( $\det \Sigma \neq 0$ ), οπότε:

$$\int (x-\mu) P_1(x) dx = 0 \Rightarrow E_{x \sim P_1} [x - \mu] = 0$$

$$\Rightarrow \boxed{\mu = E_{x \sim P_1} [x]}$$

• Για τον υπολογισμό της παραγώγου ως προς  $\Sigma$  κάνουμε χρήση των εξής εξισώσεων :

$$\frac{\partial \ln |X|}{\partial X} = (X^{-1})^T = (X^T)^{-1} \quad (\text{Εξίσωση 56 του [3]})$$

$$\frac{\partial a^T X^{-1} b}{\partial X} = -X^T a b^T X^{-T} \quad (\text{Εξίσωση 61 του [3]})$$

Άρα :

$$\begin{aligned} \frac{\partial D_{KL}(p_1(x), p_2(x))}{\partial \Sigma} &= -\frac{1}{2} \int p_1(x) \cdot \left[ \frac{\partial \ln |\Sigma|}{\partial \Sigma} + \frac{\partial (x-\mu)^T \Sigma^{-1} (x-\mu)}{\partial \Sigma} \right] dx \\ &= -\frac{1}{2} \int p_1(x) \cdot \left[ (\Sigma^T)^{-1} - \Sigma^{-T} (x-\mu) \cdot (x-\mu)^T \Sigma^{-T} \right] dx \quad \left( \begin{array}{l} \text{symmetric} \\ \Sigma^T = \Sigma \end{array} \right) \\ &= -\frac{1}{2} \int p_1(x) \cdot \left[ \Sigma^{-1} - \Sigma^{-1} (x-\mu) (x-\mu)^T \Sigma^{-1} \right] dx = 0 \end{aligned}$$

Πολλαπλασιάζοντας από αριστερά και από δεξιά με το μητρώο  $\Sigma$  :

$$\int p_1(x) \cdot \left[ \Sigma - (x-\mu)(x-\mu)^T \right] dx = 0$$

$$\Rightarrow \boxed{\Sigma = E_{x \sim p_1} [(x-\mu)(x-\mu)^T]}$$

Συνεπώς, η μετρική KL-Divergence λαμβάνει τη μικρότερη τιμή της, εφόσον η κατανομή  $p_1(x)$  που θέλουμε να προσεγγίσουμε έχει την ίδια μέση τιμή και διασπορά με τη Gaussian κατανομή  $p_2(x) \sim \mathcal{N}(\mu, \Sigma)$ .

## Άσκηση 1.6 : (Linear Regression and the LMS Algorithm)

Θεωρούμε το ακόλουθο μοντέλο γραμμικής παλινδρόμησης :

$$y = w_0 + w_1 x$$

καθώς και το παρακάτω σύνολο δεδομένων στη μορφή  $(x, y)$  :

$$\left\{ \begin{pmatrix} 0.38 \\ 2.05 \end{pmatrix}, \begin{pmatrix} 0.44 \\ 2.23 \end{pmatrix}, \begin{pmatrix} 0.48 \\ 2.13 \end{pmatrix}, \begin{pmatrix} 0.54 \\ 2.33 \end{pmatrix}, \begin{pmatrix} 0.58 \\ 2.67 \end{pmatrix}, \begin{pmatrix} 0.64 \\ 2.68 \end{pmatrix}, \begin{pmatrix} 0.71 \\ 2.81 \end{pmatrix}, \begin{pmatrix} 0.76 \\ 2.97 \end{pmatrix}, \begin{pmatrix} 0.82 \\ 3.12 \end{pmatrix}, \begin{pmatrix} 0.96 \\ 3.20 \end{pmatrix} \right\}$$

για το οποίο γνωρίζουμε ότι έχει προκύψει έπειτα από επίδραση Γκαουσιανού θορύβου.

- 1) Το γραμμικό μοντέλο υπό την επίδραση του Gaussian Noise, μπορεί να γραφεί ως εξής :

$$y = w_0 + w_1 x + \epsilon, \text{ όπου } \epsilon \sim \mathcal{N}(0, \sigma^2)$$

$$\text{άρα } y \sim \mathcal{N}(w_0 + w_1 x, \sigma^2)$$

$$\text{Likelihood Function : } p(y|x; w_0, w_1, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y - (w_0 + w_1 x))^2}{2\sigma^2} \right\}$$

Όμως, υποθέτουμε ότι τα δείγματα του συνόλου δεδομένων, έστω  $\mathcal{D}$ , είναι i.i.d. Οπότε:

$$p(y|x; w_0, w_1, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \prod_{(x,y) \in \mathcal{D}} \exp \left\{ -\frac{(y - (w_0 + w_1 x))^2}{2\sigma^2} \right\}$$

$$\Rightarrow \ln p(y|x; w_0, w_1, \sigma^2) = \cancel{\ln} -\frac{1}{2} \ln(2\pi\sigma^2) + \sum_{(x,y) \in \mathcal{D}} -\frac{(y - (w_0 + w_1 x))^2}{2\sigma^2}$$

$$\Rightarrow \ln p(y|x; w_0, w_1, \sigma^2) = -\frac{1}{2} \ln(2\pi\sigma^2) - \sum_{(x,y) \in \mathcal{D}} \frac{(y - (w_0 + w_1 x))^2}{2\sigma^2}$$

Αν θεωρήσουμε  $\hat{y} = w_0 + w_1 x$ , τότε :

$$\ln p(y|x; w_0, w_1, \sigma^2) = -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{(x,y) \in \mathcal{D}} (y - \hat{y})^2$$

Δεδομένου ότι το διάνυσμα παραμέτρων που θέλουμε να εκτιμήσουμε είναι το  $\Theta = (w_0, w_1)$ , δηλαδή τις παραμέτρους  $\Theta$ , η διασπορά  $\sigma^2$  μπορεί να

αντιμετωπίζεται ως μια απλή σταθερά στο εν λόγω πρόβλημα βελτιστοποίησης.

Επομένως :

$$\operatorname{argmax}_{\theta=(w_0, w_1)} P(y|\theta; \mathcal{D}) \stackrel{\ln(\cdot) \nearrow}{=} \operatorname{argmax}_{\theta} \ln P(y|\theta; \mathcal{D})$$

$$= \operatorname{argmax}_{\theta} - \sum_{(x,y) \in \mathcal{D}} (y - (w_0 + w_1 x))^2 = \operatorname{argmin}_{\theta=(w_0, w_1)} \sum_{(x,y) \in \mathcal{D}} (y - (w_0 + w_1 x))^2 = \operatorname{argmin}_{\theta} \underline{J_{SSE}}$$

Συνεπώς, το πρόβλημα maximum likelihood estimation για ~~το~~ την περίπτωση του linear regression, είναι ισοδύναμο με το πρόβλημα ελαχιστοποίησης του κριτηρίου  $J_{SSE}$  (Sum of Squared Errors).

2) Έστω, λοιπόν, το  $J_{SSE}$  κριτήριο για η δείγματα :

$$J_{SSE} = \sum_{i=1}^n (y_i - (w_0 + w_1 x_i))^2$$

Για να ελαχιστοποιείται, θέτουμε τις παραγώγους ως προς  $w_0$  και  $w_1$  ίσες με μηδέν :

$$\frac{\partial J_{SSE}}{\partial w_0} = 0 \Rightarrow -2 \sum_{i=1}^n (y_i - \hat{w}_0 - \hat{w}_1 x_i) = 0$$

$$\Rightarrow \hat{w}_0 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{w}_1 x_i) = \bar{y} - \hat{w}_1 \bar{x} \quad (1)$$

$$\text{όπου } \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\frac{\partial J_{SSE}}{\partial w_1} = 0 \Rightarrow -2 \sum_{i=1}^n (y_i - \hat{w}_0 - \hat{w}_1 x_i) \cdot x_i = 0$$

$$\Rightarrow \sum_{i=1}^n x_i \cdot y_i - \hat{w}_0 \sum_{i=1}^n x_i - \hat{w}_1 \sum_{i=1}^n x_i^2 = 0$$

$$\stackrel{(1)}{\Rightarrow} \sum_{i=1}^n x_i y_i - (\bar{y} - \hat{w}_1 \bar{x}) \sum_{i=1}^n x_i - \hat{w}_1 \sum_{i=1}^n x_i^2 = 0$$



$$\Rightarrow \sum_{i=1}^n x_i y_i - n \sum_{i=1}^n y_i \cdot \sum_{i=1}^n x_i + \hat{W}_1 \cdot \left( n \left( \sum_{i=1}^n x_i \right)^2 - \sum_{i=1}^n x_i^2 \right) = 0$$

$$\Rightarrow \hat{W}_1 = \frac{\sum_{i=1}^n x_i y_i - n \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{\sum_{i=1}^n x_i^2 - n \left( \sum_{i=1}^n x_i \right)^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

3) Χρησιμοποιώντας ένα από τα παραπάνω δεδομένα τη φορά, και εφαρμόζοντας τον αλγόριθμο LMS, υπολογίζουμε εκ νέου τους άγνωστους συντελεστές

$\bar{W} = (w_0, w_1)^T$ . Αρχικά, αυξάνουμε τη διαστατικότητα των δειγμάτων

ως  $\bar{x} = \begin{bmatrix} 1 \\ x_i \end{bmatrix}$ , ώστε:

$$J_{sse} = \sum_{i=1}^n (y_i - (w_0 + w_1 x_i))^2 = \sum_{i=1}^n (y_i - \bar{W}^T \bar{x})^2$$

Learning Rate:  $\eta(k) = \frac{\eta}{k+1}$ , όπου  $\eta = 1$

Ανυπαίρετη αρχικοποίηση διανύσματος βαρών  $w(0) = [1 \ 1]^T$ .

LMS Rule:  $\begin{cases} w(0) = [1 \ 1]^T \text{ arbitrarily} \\ w(k+1) = w(k) + \eta(k) \underbrace{(y(k) - \underline{w}(k)^T \cdot \underline{x}(k))}_{\nabla J} \underline{x}(k) \end{cases}$

Για  $k=0$ :  $x(k) = [1 \ 0.38]^T$ ,  $y(k) = 2.05$

$$w(1) = w(0) + 1 \cdot (2.05 - 1.38) \cdot x(0)$$

$$\Rightarrow w(1) = [1 \ 1]^T + [0.67 \ 0.2546]^T$$

$$\Rightarrow w(1) = [1.67, 1.2546]^T$$

Για k=1:  $x(1) = [1 \ 0.44]^T$ ,  $y(1) = 2.23$

$$w(2) = w(1) + \frac{1}{2} (2.23 - (1.67 + 0.44 \times 1.2546)) x(1)$$

$$\Rightarrow w(2) = [1.67 \ 1.2546]^T + [0.003988, 0.00175472]^T$$

$$\Rightarrow w(2) = [1.673988, 1.25635472]^T$$

Για k=2:  $x(2) = [1 \ 0.48]^T$ ,  $y(2) = 2.13$

$$w(3) = w(2) + \frac{1}{3} (2.13 - 1.673988 - 0.48 \times 1.25635472) \begin{bmatrix} 1 \\ 0.48 \end{bmatrix}$$

$$\Rightarrow w(3) = [1.62497524, 1.2328286]^T$$

Για k=3:  $x(3) = [1 \ 0.54]^T$ ,  $y(3) = 2.33$

$$w(4) = w(3) + \frac{1}{4} (2.33 - 1.62497524 - 1.2328286 \times 0.54) \begin{bmatrix} 1 \\ 0.54 \end{bmatrix}$$

$$\Rightarrow w(4) = [1.63479957, 1.23813373]^T$$

Για k=4:  $x(4) = [1 \ 0.58]^T$ ,  $y(4) = 2.67$

$$w(5) = w(4) + \frac{1}{5} (2.67 - 1.63479957 - 1.23813373 \times 0.58) \begin{bmatrix} 1 \\ 0.58 \end{bmatrix}$$

$$\Rightarrow w(5) = [1.69821, 1.2749]^T$$

Για k=5:  $x(5) = [1 \ 0.64]^T$ ,  $y(5) = 2.68$

$$w(6) = w(5) + \frac{1}{6} (2.68 - 1.69821 - 1.2749 \times 0.64) \begin{bmatrix} 1 \\ 0.64 \end{bmatrix}$$

$$\Rightarrow w(6) = [1.7258, 1.2926]^T$$

Για k=6:  $x(6) = [1, 0.71]^T$  και  $y(6) = 2.81$

$$w(7) = w(6) + \frac{1}{7} (2.81 - 1.7258 - 0.71 \times 1.2926) \begin{bmatrix} 1 \\ 0.71 \end{bmatrix}$$

$$\Rightarrow w(7) = [1.74962, 1.30948]^T$$

· Για  $k=7$ :  $x(7) = [1 \ 0.76]^T$ ,  $y(7) = 2.97$

$$w(8) = w(7) + \frac{1}{8} (2.97 - 1.74962 - 1.30948 \times 0.76) \begin{bmatrix} 1 \\ 0.76 \end{bmatrix}$$

$$\Rightarrow w(8) = [1.7777 \ , \ 1.3308]^T$$

· Για  $k=8$ :  $x(8) = [1 \ 0.82]^T$ ,  $y(8) = 3.12$

$$w(9) = w(8) + \frac{1}{9} (3.12 - 1.7777 - 1.3308 \times 0.82) \begin{bmatrix} 1 \\ 0.82 \end{bmatrix}$$

$$\Rightarrow w(9) = [1.80565 \ , \ 1.3537]^T$$

· Για  $k=9$ :  $x(9) = [1 \ 0.96]^T$  και  $y(9) = 3.2$


$$w(10) = w(9) + \frac{1}{10} (3.2 - 1.80565 - 1.3537 \times 0.96) \cdot \begin{bmatrix} 1 \\ 0.96 \end{bmatrix}$$

$$\Rightarrow w(10) = [1.81513 \ , \ 1.36283]^T, \text{ τέλος 1ης εποχής.}$$

4) Γράφουμε κώδικα που να εφαρμόζει τον JMS στο συγκεκριμένο πρόβλημα για 1000 εποχές και εν τέλει βρίσκουμε:

$$w = [1.20623376 \ , \ 2.23582049]^T$$

5) Παρουσιάζουμε σε κοινό γράφημα, οι ευθείες που βρέθηκαν ως λύσεις για 1 και 1000 εποχές:



## Άσκηση 1.7 : (Bayes meets KNN)

Έστω δύο ταξινομητές οι οποίοι βασίζονται σε δείγματα που προέρχονται από τις δύο κατανομές:

$$P(x|w_1) = \begin{cases} 2x, & \text{for } 0 \leq x \leq 1 \\ 0, & \text{otherwise} \end{cases}$$

$$P(x|w_2) = \begin{cases} 2-2x, & \text{for } 0 \leq x \leq 1 \\ 0, & \text{otherwise} \end{cases}$$


Επιπλέον οι α-priori πιθανότητες για κάθε κατηγορία είναι  $P(w_1) = P(w_2) = 1/2$ .

1) Κανόνας απόφασης κατά Bayes:  $\hat{w} = \underset{i=1,2}{\operatorname{argmax}} P(w_i) \cdot P(x|w_i)$

Για  $0 \leq x \leq 1$ :  $P(x|w_1) \cdot P(w_1) = P(x|w_2) \cdot P(w_2)$

$$\Rightarrow 2x \cdot \frac{1}{2} = (2-2x) \cdot \frac{1}{2} \Rightarrow 4x = 2 \Rightarrow \boxed{x = 1/2}$$

Decision Point



$$P(\text{error}) = \int_{-\infty}^{+\infty} P(\text{error}, x) dx = \int_{-\infty}^{+\infty} P(\text{error}|x) \cdot P(x) dx$$

$$= \int_{R_1} P(x|w_2) \cdot P(w_2) dx + \int_{R_2} P(x|w_1) \cdot P(w_1) dx$$

$$= \int_{1/2}^1 \left(\frac{1}{2}\right) \cdot (2-2x) dx + \int_0^{1/2} \left(\frac{1}{2}\right) \cdot 2x dx = \int_{1/2}^1 (1-x) dx + \int_0^{1/2} x dx$$

$$= \left[ x - \frac{x^2}{2} \right]_{1/2}^1 + \left[ \frac{x^2}{2} \right]_0^{1/2} = \cancel{1} - \cancel{\frac{1}{2}} - \cancel{\frac{1}{2}} + \frac{1}{8} + \frac{1}{8} = \frac{1}{4} = \underline{\underline{0.25}}$$

2) Χάρην ευκολίας, θα λύσουμε απευθείας το γενικότερο πρόβλημα για η το πλήθος σημεία σε καθεμία από τις κλάσεις  $w_1$  και  $w_2$ , ώστε να βρούμε πρώτα το  $P_n(e)$  και στη συνέχεια τις ειδικές περιπτώσεις  $P_1(e)$  και  $P_2(e)$ .

Χωρίς βλάβη της γενικότητας, υποθέτουμε ότι το test σημείο που δειγματοληπτείται, έστω  $x$ , ανήκει στην κλάση  $w_2$ . Τότε η πιθανότητα λάθους για τον nearest neighbor classifier αντιστοιχεί στην πιθανότητα το πλησιέστερο στο  $x$  σημείο των train data να ανήκει στην κλάση  $w_1$ . Δηλαδή:

$$\begin{aligned} P_n(e) &= \int_0^1 P(x|w_2) \cdot P[\text{κοντινότερο σημείο στον } x \in w_1] dx \\ &= \int_0^1 P(x|w_2) \cdot \sum_{i=1}^n P[y_i \in w_1 \text{ και } y_i \text{ κοντινότερα στο } x \text{ από το } y_j, \forall j \neq i] dx \end{aligned}$$

Λόγω συμμετρίας των p.d.f. στο διάστημα  $[0, 1]$ , οι όροι του ανωτέρω αθροίσματος είναι όλοι ίσοι μεταξύ τους: (έστω με τον όρο για  $i=1$ )

$$P_n(e) = \int_0^1 P(x|w_2) \cdot n \underbrace{P[y_1 \in w_1 \text{ και } |y_1 - x| < |y_j - x|, \forall j \neq 1]}_{\text{Ανεξάρτητα Ενδεχόμενα}} dx$$


$$\begin{aligned} \Rightarrow P_n(e) &= \int_0^1 P(x|w_2) \cdot n \int_0^1 P(w_1|y_1) \cdot P[|y_1 - x| < |y_j - x|, \forall j \neq 1] dy_1 dx \\ &= \int_0^1 P(x|w_2) \cdot n \int_0^1 P(w_1|y_1) \cdot \prod_{j=2}^n \overbrace{P[|y_1 - x| < |y_j - x|]}^{\text{λόγω συμμετρίας εσχερίνω απλώς } y_1 \text{ και } y_2} dy_1 dx \\ &= \int_0^1 P(x|w_2) \cdot n \int_0^1 P(w_1|y_1) \cdot P[|y_1 - x| < |y_2 - x|]^{n-1} dy_1 dx \end{aligned}$$

• Για τον όρο  $P(x|w_2)$  στο διάστημα  $[0, 1]$  έχουμε  $P(x|w_2) = 2 - 2x = 2(1-x)$

• Για τον όρο  $P(w_1|y_1)$  στο διάστημα  $[0, 1]$ :  $P(w_1|y_1) = \frac{P(y_1|w_1) \cdot P(w_1)}{P(y_1)} = \frac{2y_1 \cdot \frac{1}{2}}{1} = y_1$ .


Για τον όρο  $P[|y_1 - x| < |y_2 - x|]$  μελετάμε τις εξής περιπτώσεις διάταξης:

Περίπτωση 1:  $x \in [0, 1/2]$ ,  $0 < y_1 < x$




$$P[|y_1 - x| < |y_2 - x|] = 1 + 2y_1 - 2x$$

Περίπτωση 2:  $x \in [0, 1/2]$ ,  $x < y_1 < 2x$




$$P[|y_1 - x| < |y_2 - x|] = 1 + 2x - 2y_1$$

Περίπτωση 3:  $x \in [0, 1/2]$ ,  $2x < y_1 < 1$




$$P[|y_1 - x| < |y_2 - x|] = 1 - y_1$$

Περίπτωση 4:  $x \in [1/2, 1]$ ,  $0 < y_1 < 2x - 1$




$$P[|y_1 - x| < |y_2 - x|] = y_1$$

Περίπτωση 5:  $x \in [1/2, 1]$ ,  $2x - 1 < y_1 < x$



$$P[|y_1 - x| < |y_2 - x|] = 1 + 2y_1 - 2x$$

Περίπτωση 6:  $x \in [1/2, 1]$ ,  $x < y_1 < 1$



$$Pr[|y_1 - x| < |y_2 - x|] = 1 + 2x - 2y_1$$

Επομένως, κάνουμε την εξής διάσπαση:

$$\begin{aligned} P_n(e) = & \int_0^{1/2} P(x|w_2) \cdot n \cdot \left\{ \underbrace{\int_0^x P(w_1|y_1) \cdot (1 + 2y_1 - 2x)^{n-1} dy_1}_{\text{Case 1}} + \underbrace{\int_x^{2x} P(w_1|y_1) \cdot (1 + 2x - 2y_1)^{n-1} dy_1}_{\text{Case 2}} \right. \\ & \left. + \underbrace{\int_{2x}^1 P(w_1|y_1) \cdot (1 - y_1)^{n-1} dy_1}_{\text{Case 3}} \right\} dx + \int_{1/2}^1 P(x|w_2) \cdot n \cdot \left\{ \underbrace{\int_0^{2x-1} P(w_1|y_1) \cdot y_1^{n-1} dy_1}_{\text{Case 4}} + \right. \\ & \left. + \underbrace{\int_{2x-1}^x P(w_1|y_1) \cdot (1 + 2y_1 - 2x)^{n-1} dy_1}_{\text{Case 5}} + \underbrace{\int_x^1 P(w_1|y_1) \cdot (1 + 2x - 2y_1)^{n-1} dy_1}_{\text{Case 6}} \right\} dx \end{aligned}$$

Δ Για τις περιπτώσεις 1 και 5 πρέπει να υπολογίσουμε το ολοκλήρωμα:

$$I_1(a, b) = \int_a^b P(w_1 | y_1) \cdot (1 + 2y_1 - 2x)^{n-1} dy_1 = \int_a^b y_1 \cdot (1 + 2y_1 - 2x)^{n-1} dy_1$$

Θέτω  $u = 1 + 2y_1 - 2x \stackrel{u(y_1)}{=} (αλλαγή μεταβλητής)$ . Τότε:  $du = 2 dy_1 \Rightarrow dy_1 = \frac{du}{2}$

και  $y_1 = \frac{u - 1 + 2x}{2}$ . Οπότε:

$$\begin{aligned} I_1(a, b) &= \int_{u(a)}^{u(b)} \left( \frac{u - 1 + 2x}{2} \right) \cdot \left( \cancel{1} + \cancel{u} - \cancel{1} + \cancel{2x} - \cancel{2x} \right)^{n-1} \frac{du}{2} = \int_{u(a)}^{u(b)} \frac{1}{4} (u + 2x - 1) \cdot u^{n-1} du \\ &= \int_{u(a)}^{u(b)} \frac{1}{4} \cdot [u^n + (2x - 1) \cdot u^{n-1}] du = \left[ \frac{1}{4} \left( \frac{u^{n+1}}{n+1} + (2x - 1) \cdot \frac{u^n}{n} \right) \right]_{u(a)}^{u(b)} \end{aligned}$$

Άρα:

• Στην περίπτωση 1:  $I_1(0, x) = \left[ \frac{1}{4} \left( \frac{u^{n+1}}{n+1} + (2x - 1) \frac{u^n}{n} \right) \right]_{u(0) = 1 - 2x}^{u(x) = 1}$

$$\Rightarrow I_1(0, x) = \frac{1}{4} \cdot \left( \frac{1}{n+1} + (2x - 1) \cdot \frac{1}{n} - \frac{(1 - 2x)^{n+1}}{n+1} - (2x - 1) \cdot \frac{(1 - 2x)^n}{n} \right)$$

$$= \frac{1}{4} \cdot \left[ \frac{1 - (1 - 2x)^{n+1}}{n+1} + \frac{(2x - 1)}{n} \cdot (1 - (1 - 2x)^n) \right]$$

• Στην περίπτωση 5:  $I_1(2x - 1, x) = \left[ \frac{1}{4} \left( \frac{u^{n+1}}{n+1} + (2x - 1) \frac{u^n}{n} \right) \right]_{u(2x-1) = 2x-1}^{u(x) = 1}$

$$= \frac{1}{4} \left[ \frac{1}{n+1} + (2x - 1) \cdot \frac{1}{n} - \frac{(2x - 1)^{n+1}}{n+1} + \frac{(2x - 1)^{n+1}}{n} \right]$$



▷ Για τις περιπτώσεις 2 και 6 υπολογίζουμε το ολοκλήρωμα:

$$I_2(a, b) = \int_a^b P(w, y_1) (1+2x-2y_1)^{n-1} dy_1 = \int_a^b y_1 \cdot (1+2x-2y_1)^{n-1} dy_1$$

Αλλαγή Μεταβλητής  $u(y_1) = 1+2x-2y_1 \Rightarrow y_1 = \frac{1+2x-u}{2}$  και  $dy_1 = -\frac{du}{2}$

Οπότε:

$$I_2(a, b) = \int_{u(a)}^{u(b)} \frac{1+2x-u}{2} \cdot u^{n-1} \left(-\frac{du}{2}\right) = \int_{u(a)}^{u(b)} \frac{1}{4} \cdot [u^n - (1+2x) \cdot u^{n-1}] du$$

$$= \left[ \frac{1}{4} \left( \frac{u^{n+1}}{n+1} - (1+2x) \cdot \frac{u^n}{n} \right) \right]_{u(a)}^{u(b)}$$

• Στην περίπτωση 2:  $I_2(x, 2x) = \left[ \frac{1}{4} \left( \frac{u^{n+1}}{n+1} - (1+2x) \frac{u^n}{n} \right) \right]_{u(x)=1}^{u(2x)=1-2x}$

$$= \frac{1}{4} \cdot \left( \frac{(1-2x)^{n+1}}{n+1} - (1+2x) \cdot \frac{(1-2x)^n}{n} - \frac{1}{n+1} + \frac{1}{n} \cdot (1+2x) \right)$$

$$= \frac{1}{4} \cdot \left( \frac{(1-2x)^{n+1} - 1}{n+1} + \frac{(1+2x) \cdot (1 - (1-2x)^n)}{n} \right)$$

• Στην περίπτωση 6:  $I_2(x, 1) = \left[ \frac{1}{4} \left( \frac{u^{n+1}}{n+1} - (1+2x) \frac{u^n}{n} \right) \right]_{u(x)=1}^{u(1)=2x-1}$

$$= \frac{1}{4} \cdot \left[ \frac{(2x-1)^{n+1}}{n+1} - (1+2x) \cdot \frac{(2x-1)^n}{n} - \frac{1}{n+1} + \frac{(1+2x)}{n} \right]$$

Έπειτα, απομένουν δύο ακόμα περιπτώσεις: Περίπτωση 3 και 4

$$I_3 = \int_{2x}^1 P(w_1|y_1) (1-y_1)^{n-1} dy_1 = \int_{2x}^1 y_1 \cdot (1-y_1)^{n-1} dy_1$$

Αλλαγή μεταβλητής  $u(y_1) = 1-y_1 \Rightarrow y_1 = 1-u$ ,  $dy_1 = -du$  και  $u(2x) = 1-2x$ ,  $u(1) = 0$

Οπότε:

$$I_3 = \int_{1-2x}^0 (1-u) \cdot u^{n-1} (-du) = \int_{1-2x}^0 (u^n - u^{n-1}) du = \left[ \frac{u^{n+1}}{n+1} - \frac{u^n}{n} \right]_{1-2x}^0$$

$$= \frac{(1-2x)^n}{n} - \frac{(1-2x)^{n+1}}{n+1}$$

$$I_4 = \int_0^{2x-1} P(w_1|y_1) \cdot y_1^{n-1} dy_1 = \int_0^{2x-1} y_1 \cdot y_1^{n-1} dy_1 = \int_0^{2x-1} y_1^n dy_1 = \left[ \frac{y_1^{n+1}}{n+1} \right]_0^{2x-1}$$

$$= \frac{(2x-1)^{n+1}}{n+1}$$

Οπότε, μοιράζοντας τα ολοκληρώματα στις δύο μεγαλύτερες περιπτώσεις

$x \in [0, 1/2]$  και  $x \in [1/2, 1]$ :

$$P_n(e) = \int_0^{1/2} 2n(1-x) \cdot \left[ \frac{1}{4} \left( \frac{1-(1-2x)^{n+1}}{n+1} + \frac{(2x-1)}{n} \cdot (1-(1-2x))^n \right) + \frac{(1-2x)^n}{n} - \frac{(1-2x)^{n+1}}{n+1} \right]$$

$$+ \frac{1}{4} \left( \frac{(1-2x)^{n+1}}{n+1} - 1 + \frac{(1+2x)(1-(1-2x)^n)}{n} \right) dx$$

$$+ \int_{1/2}^1 2n(1-x) \cdot \left[ \frac{1}{4} \left( \frac{1-(1-2x)^{n+1}}{n+1} + \frac{(2x-1)}{n} (1-(1-2x))^n + \frac{(1-2x)^{n+1}}{n+1} - 1 + \frac{(1+2x)(1-(1-2x)^n)}{n} \right) + \frac{(2x-1)^{n+1}}{n+1} \right] dx$$

$$\Rightarrow P_n(e) = \int_0^{1/2} 2n(1-x) \cdot \underbrace{\left[ \frac{x}{n} + \frac{1}{2n} (1-2x)^n + \left( \frac{1}{2n} - \frac{1}{n+1} \right) (1-2x)^{n+1} \right]}_A dx$$

$$+ \int_{1/2}^1 2n(1-x) \cdot \underbrace{\left[ \frac{x}{n} - \frac{1}{2n} (2x-1)^n - \left( \frac{1}{2n} - \frac{1}{n+1} \right) (2x-1)^{n+1} \right]}_B dx$$

• Αλλαγή μεταβλητής στο A:

Θέτω  $u(x) = 1-2x$ , οπότε  $x = \frac{1-u}{2}$  και  $dx = -\frac{du}{2}$ , ενώ  $u(0) = 1$ ,  $u(1/2) = 0$ .

Οπότε:

$$A = \int_1^0 2n \left( \frac{1+u}{2} \right) \cdot \left[ \frac{1-u}{2n} + \frac{1}{2n} \cdot u^n + \left( \frac{1}{2n} - \frac{1}{n+1} \right) \cdot u^{n+1} \right] \left( -\frac{du}{2} \right)$$

$$= \int_0^1 \left( \frac{1+u}{2} \right) \cdot n \cdot \left[ \frac{1-u}{2n} + \frac{1}{2n} \cdot u^n + \left( \frac{1}{2n} - \frac{1}{n+1} \right) \cdot u^{n+1} \right] du$$

• Αλλαγή μεταβλητής στο B:

Θέτω  $u(x) = 2x-1 \Rightarrow x = \frac{u+1}{2}$  και  $dx = \frac{du}{2}$ , ενώ  $u(1/2) = 0$ ,  $u(1) = 1$

Οπότε:

$$B = \int_0^1 2n \cdot \left( \frac{1-u}{2} \right) \cdot \left[ \frac{u+1}{2n} - \frac{1}{2n} \cdot u^n - \left( \frac{1}{2n} - \frac{1}{n+1} \right) \cdot u^{n+1} \right] \cdot \frac{du}{2}$$

$$= \int_0^1 \left( \frac{1-u}{2} \right) \cdot n \cdot \left[ \frac{u+1}{2n} - \frac{1}{2n} \cdot u^n - \left( \frac{1}{2n} - \frac{1}{n+1} \right) \cdot u^{n+1} \right] du$$

Επομένως:

$$P_n(e) = A+B = \int_0^1 \frac{n}{2} \cdot \left[ \frac{1-u}{2n} + \frac{1}{2n} \cdot u^n + \left( \frac{1}{2n} - \frac{1}{n+1} \right) \cdot u^{n+1} + \frac{u+1}{2n} \right.$$

$$\left. - \frac{1}{2n} \cdot u^n - \left( \frac{1}{2n} - \frac{1}{n+1} \right) \cdot u^{n+1} \right] + \frac{n \cdot u}{2} \cdot \left[ \frac{1-u}{2n} + \frac{1}{2n} \cdot u^n + \left( \frac{1}{2n} - \frac{1}{n+1} \right) u^{n+1} \right.$$

$$\left. - \frac{u+1}{2n} + \frac{1}{2n} \cdot u^n + \left( \frac{1}{2n} - \frac{1}{n+1} \right) \cdot u^{n+1} \right] du$$

$$\Rightarrow P_n(e) = \int_0^1 \frac{1-u^2}{2} + \frac{u^{n+1}}{2} + \left( \frac{1}{2n} - \frac{1}{n+1} \right) \cdot n \cdot u^{n+2} du$$

$$\Rightarrow P_n(e) = \left[ \frac{u}{2} - \frac{u^3}{6} + \frac{u^{n+2}}{2(n+2)} + \left( \frac{1}{2n} - \frac{1}{n+1} \right) \cdot n \cdot \frac{u^{n+3}}{n+3} \right]_0^1$$

$$\Rightarrow P_n(e) = \frac{1}{2} - \frac{1}{6} + \frac{1}{2(n+2)} + \frac{(n+1-2n)}{2 \cdot (n+1)} \cdot \frac{n}{n+3}$$

$$\Rightarrow P_n(e) = \frac{1}{3} + \frac{1}{2(n+2)} + \frac{1-n}{(n+1)(n+3) \cdot 2}$$

$$\Rightarrow P_n(e) = \frac{1}{3} + \frac{(n+1)(n+3) + (1-n)(n+2)}{2(n+1)(n+2)(n+3)}$$

Συνεπώς για  $n=1$  το αναμενόμενο σφάλμα είναι:

$$P_1(e) = \frac{1}{3} + \frac{2 \cdot 4 + 0}{2 \cdot 2 \cdot 3 \cdot 4} = \frac{1}{3} + \frac{1}{6} = \frac{3}{6}$$

$$\Rightarrow P_1(e) = \frac{1}{2} \text{ ή } 50\%$$

2) Για  $n=2$  έχουμε:

$$P_2(e) = \frac{1}{3} + \frac{3 \cdot 5 - 4}{2 \cdot 3 \cdot 4 \cdot 5} = \frac{1}{3} + \frac{11}{120} = \frac{40+11}{120}$$

$$\Rightarrow P_2(e) = \frac{51}{120} \approx 0.425$$

3) Στη γενικότερη περίπτωση των  $n$  σημείων δείξαμε ότι:

$$P_n(e) = \frac{1}{3} + \frac{(n+1)(n+3) + (1-n)(n+2)}{2(n+1)(n+2)(n+3)}$$

$$4) P_{NN} = \lim_{n \rightarrow \infty} P_n(e) = \lim_{n \rightarrow \infty} \frac{(n+1)(n+2) + (1-n)(n+2)}{2(n+1)(n+2)(n+3)} + \frac{1}{3} = \underline{\underline{\frac{1}{3}}}$$

Ενώ στο Ερώτημα 1 βρήκαμε για τον Bayes Classifier :

$$P_{\text{Bayes}} = \frac{1}{4} = 0.25$$

Παρατηρούμε ότι ισχύει  $P_{NN} > P_{\text{Bayes}}$ , για  $n \rightarrow \infty$ , ενώ μάλιστα ικανοποιείται και η Εξίσωση ~~50~~ στο κεφ 4.5 του [2] για  $C=2$  κλάσεις :

$$P_{\text{Bayes}} \leq P_{NN} \leq P_{\text{Bayes}} \left( 2 - \frac{C}{C-1} \cdot P_{\text{Bayes}} \right)$$

$$\Rightarrow \boxed{\frac{1}{4} \leq \frac{1}{3} \leq \frac{3}{8}}$$

### Άσκηση 1.8: (EM)

Θεωρούμε τα δεδομένα:

$$D = \left\{ \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \begin{pmatrix} 4 \\ 5 \end{pmatrix}, \begin{pmatrix} 1 \\ * \end{pmatrix} \right\}$$

όπου το  $*$  υποδηλώνει μια άγνωστη τιμή χαρακτηριστικού. Υποθέτουμε πως τα σημεία αυτά έχουν προέλθει από μία διδιάστατη διαχωρίσιμη κατανομή  $p(x_1, x_2) = p(x_1)p(x_2)$  με:

$$p(x_1) \sim \begin{cases} \frac{1}{\theta_1} e^{-\theta_1 x_1}, & \text{εάν } x_1 \geq 0 \\ 0, & \text{αλλιώς} \end{cases}$$

$$p(x_2) \sim U(0, \theta_2) = \begin{cases} 1/\theta_2, & \text{εάν } 0 \leq x_2 \leq \theta_2 \\ 0, & \text{αλλιώς} \end{cases}$$

#### 1) Expectation Step:

Θεωρούμε αρχική εκτίμηση παραμέτρων  $\theta^{(0)} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$ . Τότε:

$$Q(\theta; \theta^{(0)}) = E_{x_{32}} [\ln p(D_g, D_b; \theta) | \theta^{(0)}, D_g]$$

όπου  $D_g = \{x_1, x_2, x_{31}\}$  και  $D_b = \{x_{32}\}$ .

$$Q(\theta; \theta^{(0)}) = \int_{-\infty}^{+\infty} [\ln p(x_1 | \theta) + \ln p(x_2 | \theta) + \ln p(x_3 | \theta)] \cdot p(x_{32} | \theta^{(0)}, x_{31} = 1) dx_{32}$$

Εν γένει:

$$\begin{aligned} \int_{-\infty}^{+\infty} p(x_{32} | \theta^{(0)}, x_{31} = 1) dx_{32} &= \int_0^{\theta_2^{(0)}} \frac{1}{\theta_1^{(0)}} e^{-\theta_1^{(0)} \cdot x_{31}} \cdot \frac{1}{\theta_2^{(0)}} dx_{32} \\ &= \int_0^3 \frac{1}{2} e^{-2} \cdot \frac{1}{3} dx_{32} = \frac{e^{-2}}{2} \end{aligned}$$

Οπότε :

$$\begin{aligned} Q(\theta; \theta^{(0)}) &= \frac{1}{2e^2} \left[ \ln p(\underline{x}_1 | \theta) + \ln p(\underline{x}_2 | \theta) \right] + \underbrace{\int_{-\infty}^{+\infty} \ln p(\underline{x}_3 | \theta) \cdot p(\underline{x}_{32} | \theta^{(0)}, x_{31}=1) d\underline{x}_3}_{I} \\ &= \frac{1}{2e^2} \left[ \ln\left(\frac{1}{\theta_1} \bar{e}^{\theta_1} \cdot \frac{1}{\theta_2}\right) + \ln\left(\frac{1}{\theta_1} \bar{e}^{-4\theta_1} \cdot \frac{1}{\theta_2}\right) \right] + I \\ &= \frac{1}{2e^2} \left[ -\theta_1 - \ln \theta_1 - \ln \theta_2 - 4\theta_1 - \ln \theta_1 - \ln \theta_2 \right] + I \\ &= \frac{1}{2e^2} \left[ -5\theta_1 - 2\ln \theta_1 - 2\ln \theta_2 \right] + I \end{aligned}$$

Για τον υπολογισμό του ολοκληρώματος  $I$  διακρίνουμε τις εξής υποπεριπτώσεις :

(i)  $\theta_2 \leq 3$  και  ~~$\theta_2 \leq 3$  και  $\theta_2 \leq 3$~~  προφανώς  $\theta_2 \geq 0$

$$I = \int_0^{\theta_2} \ln\left(\frac{1}{\theta_1} \bar{e}^{\theta_1} \cdot \frac{1}{\theta_2}\right) \cdot \frac{1}{2} \bar{e}^{-2} \cdot \frac{1}{3} d\underline{x}_{32}$$

$$= \frac{e^{-2}}{2} \cdot \left[ \frac{1}{3} \theta_2 \cdot \ln\left(\frac{1}{\theta_1} \bar{e}^{\theta_1} \cdot \frac{1}{\theta_2}\right) \right]$$

(ii)  $\theta_2 \geq 3$  :

$$I = \int_0^3 \ln\left(\frac{1}{\theta_1} \bar{e}^{\theta_1} \cdot \frac{1}{\theta_2}\right) \cdot \frac{1}{2} \bar{e}^{-2} \cdot \frac{1}{3} d\underline{x}_{32}$$

$$= \frac{e^{-2}}{2} \cdot \ln\left(\frac{1}{\theta_1} \bar{e}^{\theta_1} \cdot \frac{1}{\theta_2}\right)$$

(iii) Σε κάθε άλλη περίπτωση  ~~$\theta$~~   $I = 0$ .

Επομένως :

(i) Για  $0 \leq \theta_2 \leq 3$  :

$$Q(\theta; \theta^{(0)}) = \frac{1}{2e^2} \cdot \left[ -5\theta_1 - 2\ln\theta_1 - 2\ln\theta_2 - \frac{1}{3}\theta_2\ln\theta_1 - \frac{1}{3}\theta_1\theta_2 - \frac{1}{3}\theta_2\ln\theta_2 \right]$$

(ii) Για  $\theta_2 \geq 3$  :

$$Q(\theta; \theta^{(0)}) = \frac{1}{2e^2} \cdot \left[ -5\theta_1 - 2\ln\theta_1 - 2\ln\theta_2 - \ln\theta_1 - \theta_1 - \ln\theta_2 \right]$$

$$\Rightarrow Q(\theta; \theta^{(0)}) = \frac{1}{2e^2} \cdot \left[ -6\theta_1 - 3\ln\theta_1 - 3\ln\theta_2 \right]$$

2) Αρχικά, επιθυμούμε να ικανοποιείται η συνθήκη κανονικοποίησης πιθανότητας για την  $p(x_1)$ , δηλαδή :

$$\int_{-\infty}^{+\infty} p(x_1) dx_1 = 1 \Rightarrow \int_0^{+\infty} \frac{1}{\theta_1} \cdot e^{-\theta_1 x_1} dx_1 = 1$$

$$\Rightarrow \left[ -\frac{1}{\theta_1^2} \cdot e^{-\theta_1 x_1} \right]_0^{+\infty} = 1 \Rightarrow 0 + \frac{1}{\theta_1^2} \cdot e^{-\theta_1 \cdot 0} = 1$$

$$\Rightarrow \theta_1^2 = 1 \xrightarrow{\theta_1 \geq 0} \boxed{\theta_1 = 1}$$

Οπότε :

(i) Για  $0 \leq \theta_2 \leq 3$  :

$$Q(\theta; \theta^{(0)}) = \frac{1}{2e^2} \cdot \left[ -5 - 2 \cdot 0 - 2\ln\theta_2 - \frac{1}{3}\theta_2 \cdot (0 + 1 \cdot \theta_2 + \ln\theta_2) \right]$$

$$= \frac{1}{2e^2} \cdot \left[ -5 - 2\ln\theta_2 - \frac{1}{3}\theta_2 - \frac{1}{3}\theta_2\ln\theta_2 \right]$$

$$= \frac{1}{2e^2} \cdot [-5]$$

Maximisation Step:  $\frac{\partial Q(\theta; \theta^{(0)})}{\partial \theta_2} = 0 \Rightarrow \frac{-2}{\theta_2} - \frac{1}{3} - \frac{1}{3}\ln\theta_2 - \frac{1}{3} = 0$

Άτοπο για  $\theta_2 \in (0, 3]$



Παρατηρούμε, ωστόσο, ότι για  $\theta_2 \in [0, 3]$  ισχύει  $\frac{\partial Q}{\partial \theta_2} < 0$ , οπότε η συνάρτηση  $Q(\theta; \theta^{(0)})$  είναι γνησίως φθίνουσα και λαμβάνει την υψηλότερη τιμή της για  $\theta_2 = 0$ , οπότε  $Q = +\infty$ .

(ii) Για  $\theta_2 \geq 3$ :

$$Q(\theta; \theta^{(0)}) = -\frac{1}{2e} \cdot [6 + 3 \ln \theta_2]$$

$$\frac{\partial Q}{\partial \theta_2} = -\frac{3}{2e\theta_2} < 0, \forall \theta_2 \geq 3 \rightarrow \text{επίσης γνησίως φθίνουσα.}$$


$$\text{Άρα } \arg\max_{\theta_2} Q = 3, \text{ όπου } Q(\theta_2=3) = -\frac{1}{2e} \ln 9.$$

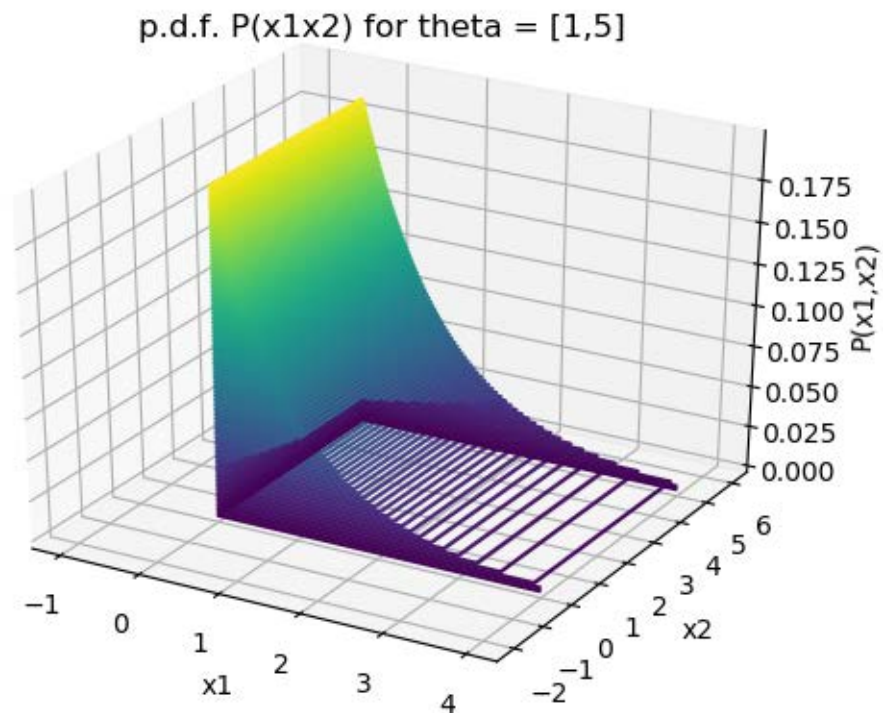
Σε κάθε περίπτωση, όμως, μπορούμε να συμπεράνουμε πως η συνάρτηση  $Q(\theta; \theta^{(0)})$  δεν παρουσιάζει κάποιο τοπικό μέγιστο ως προς  $\theta_2$ , αφού  $\lim_{\theta_2 \rightarrow 0} Q(\theta) = +\infty$ .

Συνεπώς, επιλέχουμε ως  $\theta_2^{(1)} = \max_i x_2^{(i)} = 5$ .

Άρα  $\theta^{(1)} = \begin{bmatrix} 1 \\ 5 \end{bmatrix}$  το νέο διάνυσμα παραμέτρων.

3)





## ▲ References

- [1] R. O. Duda, P.E. Hart and D.G. Stork, Pattern Classification, Wiley, 2001, Chapter 2: Bayesian decision theory.
- [2] R. O. Duda, P.E. Hart and D.G. Stork, Pattern Classification, Wiley, 2001, Chapter 4: Nonparametric techniques.
- [3] The Matrix Cookbook, K.B. Petersen, M.S Pedersen, November 15, 2012

# 1 Supplementary Code

```
1 """
2 Pattern Recognition - Flow S
3 Exercise 1.4: Perceptron
4 Christos Dimopoulos - 03117037
5 """
6
7 import numpy as np
8 import matplotlib.pyplot as plt
9 plt.close('all')
10
11 rho = 1 # learning rate
12 weights = np.array([0,0,0]) # initial weight vector
13 # Input Data
14 xdata = np.array([[1, 2, 1.5],
15                  [1, 4, 1],
16                  [1, -3, 3],
17                  [1, -2, 2],
18                  [1, 0, 3],
19                  [1, -1, 0],
20                  [1, 0, 0],
21                  [1, 2, -0.5],
22                  [1, 1, -1],
23                  [1, -2, 1]
24                  ]) #always starts with 1
25
26 # 0 --> w1 class, 1 --> w2 class
27 y_labels = [0,0,0,0,0, 1,1,1,1,1]
28
29 counter = 0
30 j = 0
31 while counter!=10: # that is all 10 samples are classified
32     # correctly
33     for i in range(xdata.shape[0]):
34         j+=1
35         inner_product = np.dot(weights, xdata[i])
36
37         if (y_labels[i]==0 and inner_product <=0):
38             weights = weights +rho*xdata[i]
39             counter = 0
40         elif (y_labels[i]==1 and inner_product>=0):
41             weights = weights - rho*xdata[i]
42             counter = 0
43         else:
44             counter=counter+1
45             if counter==10:
46                 break
47
48 print('After '+str(j)+' iterations the Weight Vector is [w0, w1, w2
49       ] = ',weights)
50
51 # Plot Result
52 blacks = [(2,1.5),(4,1),(-3,3),(-2,2),(0,3)] # w1 class
53 whites = [(-1,0),(0,0),(2,-0.5),(1,-1),(-2,1)] # w2 class
54
55 def coords(data):
```

```

54     xs, ys = [], []
55     for point in data:
56         xs.append(point[0])
57         ys.append(point[1])
58     return xs, ys
59
60 black_x, black_y = coords(blacks)
61 plt.figure()
62 plt.grid()
63 plt.scatter(black_x, black_y, color='b', label = 'Class w1')
64
65 white_x, white_y = coords(whites)
66 plt.scatter(white_x, white_y, color='r', label = 'Class w2')
67
68 # draw perceptron
69 N = 5
70 x1 = np.linspace(-N,N,100)
71 x2 = (-weights[0]-weights[1]*x1)/weights[2]
72
73 plt.plot(x1, x2, color = 'm', label = 'Perceptron Decision Boundary'
74         )
75 plt.xlabel('x1')
76 plt.ylabel('x2')
77 plt.xticks(np.arange(-N, N+1, 1))
78 plt.yticks(np.arange(-N, N+1, 1))
79 plt.axvline(0, color='k')
80 plt.axhline(0, color = 'k')
81 plt.legend()
82 plt.show()

```

```

1  """
2  Pattern Recognition - Flow S
3  Exercise 1.6: Linear Regression
4  Christos Dimopoulos - 03117037
5  """
6
7  import numpy as np
8  import matplotlib.pyplot as plt
9  plt.close('all')
10
11 data = [(0.38, 2.05), (0.44, 2.23), (0.48, 2.13), (0.54, 2.33),
12         (0.58, 2.67), (0.64, 2.68),
13         (0.71, 2.81), (0.76, 2.97), (0.82, 3.12), (0.96, 3.2)]
14
15 x = np.array([[i[0]] for i in data])
16 y = np.array([[i[1]] for i in data])
17
18 xnew = np.concatenate((np.ones((10,1)),x),axis=1)
19
20 h = 1 # learning rate
21
22 weights = np.array([1, 1]) # random initialization
23
24 # LSE Algorithm
25 for epochs in range(1000):
26     for i in range(len(xnew)): # one sample at a time
27         # Gradient of MSE
28         gradient = (y[i]-np.dot(weights, xnew[i]))*xnew[i]

```

```

28     weights = weights + (h/(i+1))*gradient
29     if epochs==0:
30         weights_first = weights #collect weights after 1st epoch
31         for comparison
32 print('After 1 epoch: [w0,w1] = ',weights_first)
33 print('After 1000 epochs: [w0,w1] = ',weights)
34
35 # Plot Result
36 plt.figure()
37 plt.grid()
38 # Draw samples
39 plt.scatter(x, y, color='b')
40
41 # Draw Line after 1st Epoch
42 x1 = np.linspace(-1,2,100)
43 x2= weights_first[0]+weights_first[1]*x1
44 plt.plot(x1, x2, color = 'm', label = 'Regression after 1 epoch')
45
46 # Draw line after 1000 epochs
47 N = 3
48 x1 = np.linspace(-1,2,100)
49 x2= weights[0]+weights[1]*x1
50 plt.plot(x1, x2, color = 'r', label = 'Regression after 1000 epochs
51 ')
52 plt.xlabel('x')
53 plt.ylabel('y')
54 plt.axvline(0, color='k')
55 plt.axhline(0, color = 'k')
56 plt.legend()
57 plt.show()

```

```

1  """
2  Pattern Recognition - Flow S
3  Exercise 1.8: EM
4  Christos Dimopoulos - 03117037
5  """
6  import numpy as np
7  import matplotlib.pyplot as plt
8  from mpl_toolkits.mplot3d import Axes3D
9  plt.close('all')
10
11 x1 = np.linspace(-1,4,1000)
12 x2 = np.linspace(-2,6,1000)
13
14 theta0 = [2, 3]
15 theta1 = [1, 5]
16
17 # Exponential Distribution
18 def exponential(x1, theta):
19     return (1/theta[0])*np.exp(-theta[0]*x1)*(x1>=0)
20
21 def uniformal(x2, theta):
22     return 1/theta[1]*(x2>=0)*(x2<=theta[1])
23
24 # Plot p.d.f. before EM
25 X1, X2 = np.meshgrid(x1, x2)

```

```

26 p1 = exponential(X1, theta0)
27 p2 = uniformal(X2, theta0)
28 p_beforeEM = p1*p2
29
30 fig = plt.figure()
31 ax = fig.add_subplot(111, projection='3d')
32 ax.contour3D(X1, X2, p_beforeEM, 100)
33 ax.set_xlabel('x1')
34 ax.set_ylabel('x2')
35 ax.set_zlabel('P(x1,x2)')
36 ax.set_title('p.d.f. P(x1x2) for theta = [2, 3]')
37
38 # Plot p.d.f. after EM
39 p1 = exponential(X1, theta1)
40 p2 = uniformal(X2, theta1)
41 p_afterEM = p1*p2
42
43 fig = plt.figure()
44 ax = fig.add_subplot(111, projection='3d')
45 ax.contour3D(X1, X2, p_afterEM, 100)
46 ax.set_xlabel('x1')
47 ax.set_ylabel('x2')
48 ax.set_zlabel('P(x1,x2)')
49 ax.set_title('p.d.f. P(x1x2) for theta = [1,5]')

```